

# Çekişmeli Üretici Ağlar ile Özgün Uyumlu Kıyafet Tasarımı Oluşturulması

## Automatic Generation of Matching Clothes Design Using Generative Adversarial Networks

Mehmet Önder, Yusuf Sinan Akgül  
Bilgisayar Mühendisliği Bölümü  
Gebze Teknik Üniversitesi, Kocaeli, 41400, Türkiye  
mehmet@istanbulai.com, akgul@gtu.edu.tr

### I. GİRİŞ

**Özetçe—** Bu bildiri; tekstil sektöründe önemli bir problem olan yeni kıyafet tasarımı ile ilgili özgün bir çözüm önermektedir. Bu sistem sayesinde uyumlu kıyafetler saniyeler içerisinde üretilecektir. Ayrıca sektörün tasarım maliyeti en aza indirilip istenilen, uzun süren tasarım süreci daha kısa sürede, daha çok sayıda yerine getirilecektir. Oluşturulan sistem son zamanlarda sıklıkla kullanılan Derin Öğrenme yöntemlerinden olan Çekişmeli Üretici Ağlar (ÇÜA) ile geliştirilmiştir. Verilen bir kıyafet için uyumlu kıyafet üretilebildiği gibi istenilen kategoride ve istenilen sayıda farklı tasarımlar da oluşturulabilmektedir. Tüketici tarafında da bu sistemin faydaları bulunmaktadır. Firmaların çok fazla tasarım ihtiyacından meydana gelen bir problem ise farklı tasarımlara ürün üretilmesidir. Tüketici bir markadan aldığı ürünü diğer bir markada görme ihtimali oldukça yüksektir. Bu sistem sayesinde farklı tasarım örnekleri oluşturulabilecek ve birbiri ile uyumlu olarak tasarlanabilecektir. Getirilen sistemin validasyonu, üretilen tasarım sonuçlarının gönüllü deneklere gösterilmesi yöntemiyle sağlanarak, önerilen yöntemin pratik olarak kullanılabileceği anlaşılmıştır.

**Anahtar Kelimeler:** Çekişmeli Üretici Ağlar, Şartlı Çekişmeli Üretici Ağlar, Derin Öğrenme, Kıyafet Tasarımı.

**Abstract—** This paper introduces a new automated system for designing new clothes. Given sample clothes, this system generates matching cloth designs in a few seconds. Optimizing the new cloth design times and decreasing the cost of such designs are some of the main desires of the textile industry, which can be achieved with the help of the system proposed. Our system employs Generative Adversarial Networks of deep learning techniques, which became very popular for many applications. The proposed system has also some valuable properties for the consumers, such as having a completely original design that no other clothing brand offers. We validated the proposed system by performing experiments on volunteers by showing the produced designs and getting their opinions. We are very encouraged by the initial results and we think that the system may be applicable for practical employment.

**Keywords:** Generative Adversarial Networks, Conditional Generative Adversarial Networks, Deep Learning, Clothes Design.

Tekstil sektöründe önemli bir problem olan yeni kıyafet tasarımı ile ilgili bir çözüm sistemi oluşturulmuştur. Bu sistem sayesinde uyumlu kıyafetler saniyeler içerisinde verilebilecektir. Ayrıca sektörün tasarım maliyeti en aza indirilip, uzun süren tasarım süreci daha kısa sürede daha çok sayıda yapılabilecektir. Oluşturulan sistem son zamanlarda sıklıkla kullanılan Derin Öğrenme yöntemlerinden olan Çekişmeli Üretici Ağlar (ÇÜA) ile geliştirilmiştir. Uyumlu kıyafet üretilebildiği gibi istenilen kategoride istenilen sayıda farklı tasarımlar da oluşturulabilmektedir. Tüketici tarafından da bu sistemin faydaları bulunmaktadır. Firmaların çok fazla tasarım ihtiyacından meydana gelen bir problem ise farklı tasarımlarda ürün üretilmemesidir. Tüketici bir markadan aldığı ürünü diğer bir markada görme ihtimali oldukça yüksektir. Bu sistem sayesinde farklı tasarım örnekleri oluşturulabilecek ve birbirleriyle uyumlu olarak tasarlanabilecektir. Bu çalışmamızda sektördeki tasarım sorunu çözülmeye çalışılmıştır. Uyumlu olan kıyafetlerin ÇÜA metotlarını kullanarak eğitilip, yeni uyumlu kıyafet tasarımı yapabilen sistem geliştirilmiştir. Yapılan çalışmalar sonucunda alt kıyafet olarak verilen, kıyafete uygun birçok üst kıyafetin üretilmesi sağlanmıştır. Ayrıca çalışmalarımız sadece uyumluluk üzerine olmayıp, istenilen bir kategoride istenilen sayıda, istenilen stilde kıyafet üretimi yapabilen sistem olarak tasarlanmıştır. Sistemin tasarladığı tüm kıyafetler, tekrar eden tasarımlar olmayıp, birbirinden farklı tasarımlar üretebilmektedir. Sistem sektördeki tasarımcı maliyetlerini azaltabileceği gibi, üretim süresini de çok kısa sürelerle indirilebilir hale getirecektir.

### II. YÖNTEM

#### A. Veri Kümesinin Hazırlanması

Uyumlu kıyafet üretimi için, Amazon web sitesinin yayınlamış olduğu, müşteriler tarafından satın alınmış olan kıyafetlerin bilgileri bulunmaktadır. Veri kümesi kullanarak, kıyafetler ilk olarak kategorilerine göre ayırıp, birinci veri kümesi oluşturulmuştur. İkinci olarak, uyumlu olan alt ve üst

kıyafetlerin gruplandırıldığı ayrı bir veri kümesi oluşturulmuştur. Kategorilerine göre ayrılan veri kümesinde toplamda 40 bin görüntü, uyumlu olan verilerin bulunduğu veri kümesinde ise 13 bin veri bulunmaktadır.

#### B. Çekişmeli Üretici Ağlar (ÇÜA) ile Yeni Kıyafet Tasarımı

ÇÜA yönetimi, derin öğrenme dünyasında son yıllarda oldukça sıklıkla kullanılan yöntemler olarak karşımıza çıkmaktadır [1],[2]. Bu yöntem temel olarak, çekişme içerisinde olan iki farklı derin ağı birbirlerinin açıklarını kullanarak kendi görevlerini belli süre sonra daha yapmaları prensibine dayanmaktadır. ÇÜA kullanılarak doğal dil işlemlerinden [3], [4] tıp görüntü [5], [6] uygulamalarına kadar birçok alanda başarılı sonuçlar elde edilmiştir. Önerilen sistem ise Nvidia tarafından geliştirilen [7] ProGAN yöntemini kullanmaktadır. Bu çalışmada üç milyon görüntü ile insan yüzü sentezlenmesi gerçekleştirilmiştir. ProGAN modeli temel olarak, girdi olarak verilen görüntülerin farklı çözünürlüklerle eğitilip, görüntüye ait özelliklerin model tarafından daha iyi öğrenilmesi sağlanmıştır. Ayrıca model, diğer modellere kıyasla daha hızlı ve çeşitli çıktılar verebilmektedir. Bu çalışmayı göz önüne alarak, ilk olarak iki ayrı kategoride eğitim gerçekleştirilmiştir. Aldığımız başarılı sonuçlar neticesinde çalışmalarımıza bu model üzerinden devam etmek uygun görülmüştür. Yaptığımız eğitimin örnek çıktıları aşağıda Şekil 1’de gösterilmiştir. Eğitim toplamda 40 saat sürmüştür.



Şekil 1 ProGAN farklı kategorilere ait verilerin eğitim sonuçları gösterilmiştir.

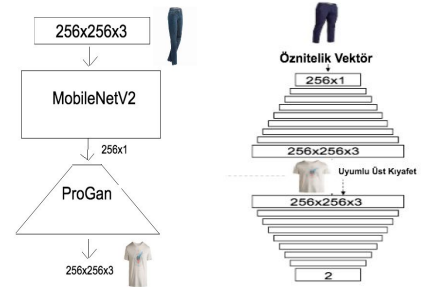
#### C. Alt Kıyafetlerin Öznelik Vektörünün Çıkarılması

Alt kıyafetlerin özelliklerini çıkarabilmek için bir model eğitilmiştir. Bu model MobileNet V2 [8] modeli üzerinde değişiklik yapılarak oluşturulmuş olup, parametre sayısı olarak küçük ve tahmin süresi hızlı bir model olarak tasarlanmıştır. MobileNet V2 yapısı, derinlemesine ayrılabilir konvolüsyon kullanır. Bu sayede model ağırlıkları ortak kullanılarak daha az parametreye sahiptir. Modelin az parametre içermesinden kaynaklı yapılan sorgu süreleri diğer modellere göre [9], [10] daha hızlı sonuçlar vermektedir. Modelde son iki katman sonradan eklenmiş olup, ImageNet ağırlıkları ile ilklendirilerek tekrar eğitim yapılmıştır. Sondan bir önceki katmana 256 yoğun nöron eklenmiştir. Kategorilerin sınıflandırılabilmesi için son katman olarak 42 yoğun nöron içeren bir katman daha eklenmiş ve bu katman modelin çıktısı olarak gösterilmiştir. Tüm kıyafetleri kategorilerini sınıflandıracak şekilde eğitildiğinde, eklemiş olduğumuz 256 çıktısı olan vektör, her bir kıyafet için

öznelik saklayan katman haline gelecektir. Kıyafet hakkında bilgi edinebilmek için belirtilen 256 vektörün bilgisi yeterli olacaktır. Oluşturulan model eğitimi belirtilen kategorilere ait veri kümesi ile yapılmış olup, model başarı sonuçları Şekil 12’te gösterilmiştir.

#### D. Koşullu Çekişmeli Üretici Ağlar (KÇÜA) Modeli ile Yeni Kıyafet Tasarımı

Önceki yapılan ÇÜA eğitimi sonrasında uyumlu olan kıyafet üretimi için ProGAN modelini koşullu çekişmeli üretici ağı haline getirip, yeni bir eğitim yapılmasına karar verildi. Eğitimde Amazon veri kümesinin uyumlu olan kıyafetlerin bulunduğu veri kümesi ile KÇÜA eğitimi yapılmıştır. Oluşturulan model aşağıdaki Şekil 2’deki gibi tasarlanmıştır.



Şekil 2 Oluşturulan KÇÜA modelinin şeması gösterilmektedir.

Modeli eğitmek için girdi olarak uyumlu olan alt ve üst kıyafetlerden, alt kıyafetin öznelik vektörü verilip, çıktı olarak uyumlu olan üst kıyafetin üretilmesi sağlanmıştır. Her bir alt kıyafetin öznelik bilgileri, yukarıda belirtilmiş olan 256 adet çıktı veren katmana ait vektör ile temsil edilmektedir. Alınan sonuçlar Şekil 3’te gösterilmiştir. Alınan sonuçların çıktıları 512x512 boyutundadır. Yüksek çözünürlükteki çıktıların optimizasyonu daha zor olduğu için, stil tasarımların daha bulanık ve karmaşık çıktığı gözlemlenmiştir. Sorunu çözmek için 256x256 boyutunda tekrar eğitim yapılmıştır. Bu eğitim sonuçları da Şekil 4’teki gibidir.



Şekil 3 Alt kıyafete ait 256 tane öznelik vektörü ile 512x512 boyutunda yapılan eğitim sonuçları gösterilmiştir.



Şekil 4 Alt kıyafete ait 256 tane öznelik vektörü ile 256x256 boyutunda yapılan eğitim sonuçları gösterilmiştir.

Şekil 4'te üretilen her bir üst kıyafet, veri kümesinde önceden eşleştirilmiş olan alt kıyafetin özelliklerine göre sistem tarafından oluşturulmuştur. Her bir alt kıyafet önceden oluşturduğumuz MobileNet v2 modeline girdi olarak verilmiştir. Sonuç olarak alınan 256 yoğun katman sonucu Şekil 2'deki gibi ProGAN modeline verilmiştir. Model çıktısının eğitimi, veri kümesindeki uyumlu üst kıyafet ile yapılmıştır. Uyumluluk sonuçları ise Şekil 5'teki gibi örneklendirilmiştir.




Şekil 5 İlk sütundaki alt kıyafet görsellerinin, modele girdi olarak verildikten sonra sistem tarafından tasarlanan sonuç üçüncü sütunda gösterilmiştir. İkinci sütundaki üst kıyafet ise modelin eğitim veri kümesindeki uyumlu olarak gösterilen üst kıyafettir.

Yapılan testler sonucunda, verilen 256 öznitelik vektörü ile üretilen üstler, hep aynı varyasyon sonucunda üretilmiş sonuçlardır. Bu yüzden ProGAN modelinde üretilen kıyafetler hep aynı sonucu üretmektedir. Bir sonraki aşamada bu problem için çözüm yöntemi geliştirilmiştir.

#### E. Yeniden Düzenlenen (KÇÜA) Modeli ile Yeni Kıyafet Tasarımı

Verilen alt kıyafete uygun farklı üst kıyafetler üretebilmek için, her bir örneğe özel farklı girdilerin verilmesi söz konusudur. Bu nedenle ÇÜA modellerinde genellikle standart dağılıma uygun rastgele girdiler verilmektedir. Bir önceki yaptığımız çalışma sonucunda, her bir girdi için sadece tek bir varyasyonda üst kıyafet üretebildiğimizi belirtmiştik. Öznitelik vektörü ile birlikte 256 tane standart dağılıma uygun girdi daha ekleyerek, üst kıyafetin farklı varyanslarını üretebilir hale getirebiliriz. Bunun için 256 girdi daha ekleyerek modelin Şekil 6'da gösterilen tasarımı sağlanmıştır.




Şekil 6 Girdi olarak verilen alt kıyafete ait öznitelik vektörü haricinde rastgele 256 tane daha girdi verilerek farklı varyasyonların oluşması için tasarlanan KÇÜA modeli gösterilmiştir.



Şekil 7 Alt kıyafetin öznitelik vektörü ve 256 tane rastgele sayı verilen modelin, ürettiği uyumlu üst kıyafetler gösterilmiştir

Şekilde gösterildiği üzere uyumlu bir üst kıyafet sentezleyebilmek için girdi olarak alt kıyafet verildiğinde, oluşturduğumuz MobileNet modeli 256 çıktısı olan özelliklerin bulunduğu bir vektör vermektedir. Bu vektör ile birlikte 256 rastgele (rnd) girdi birleştirilip, oluşturduğumuz KÇÜA modeline verildiğinde uyumlu bir üst kıyafet üretilmektedir. Modelin örnek çıktıları Şekil 7'deki gibidir.



Şekil 8 Girdi olarak alt kıyafetin fotoğrafını input olarak verildiği, çıktı olarak ise uyumlu olan üst kıyafetin sonuç olarak gösterildiği Oto Kodlayıcı model şeması gösterilmiştir.

#### F. Değişimsel Oto Kodlayıcı (DOK) ile Yeni Kıyafet Tasarımı

Derin öğrenmede veri sentezlemek için kullanılan diğer bir yöntem DOK'dir [11]. Oto kodlayıcı, girdi katmanı, gizli katman ve çıktı katmanı olmak üzere üç katmandan meydana gelen tam bağlı bir yapay sinir ağıdır. Ağın giriş çıkışında kullanılan veri kümesi aynı olduğundan girdi katmanı ve çıktı katmanındaki nöron sayıları birbirine eşit ve veri setindeki öznitelik sayısı kadardır. Gizli katmandaki nöron sayısı ise uygulamaya göre belirlenmektedir ve bu sayı ağın performansını etkileyen önemli bir unsurdur. Kodlayıcı, kendi giriş verisini en az kayıpla yine kendine haritalayan bir kodlayıcı gibi çalışmaktadır. Orta katmanda, giriş ve çıkış katmanından daha az sayıda nöron kullanılması durumunda, boyutu düşürülen veri orta katmanın çıkışından elde edilir. Temel amacı en az kayıpla boyutu en aza indirmek olan bu modelde, girdi katmanından gizli katmana, gizli katmandan da çıktı katmanına aktarılır [12]. Fakat bizim oluşturduğumuz modelde uyumlu olan üst kıyafet üretilmesi için, standart DOK modelini üzerinde değişiklikler yapılarak çalışmamıza uygun hale getirilmiştir. Modelimize girdi olarak alt kıyafet, çıktı olarak uyumlu üst kıyafet verilerek modelimiz eğitilmiştir. Modelimizin tasarımı Şekil 8'deki gibidir. Yapılan eğitim yaklaşık 7 gün sürmüş olup modelin örnek çıktıları Şekil 9 gibidir.



Şekil 9 Girdi olarak alt kıyafet fotoğrafının verildiği, çıktı olarak ise uyumlu olan üst kıyafetin sonuç olarak gösterildiği DOT modelin eğitim sonuçları gösterilmiştir.

### III. DENEYLER

#### A. Anket Değerlendirmesi

Yapılan çalışmalarda gönüllüler üzerinde anket için web uygulaması oluşturulmuştur. Sonuçları değerlendirmek için bu anket üzerinde ÇÜA ile yapılan iki farklı modeli, DOK ile yapılan çalışmanın iki örneğini ve Orijinal veri kümesindeki uyumlu üst kıyafetin görüntüleri seçenек olarak sunulmuştur. ÇÜA ve DOK çıktıları düşük çözünürlükte ve bulanık görünümde olduğu için orijinal görüntülerin boyutları, ilk olarak belli bir miktar küçültülüp ardından sabit bir boyutta gösterilmiştir. Toplamda 11 farklı gönüllü denekten değerlendirme alınmış olup, yapılan sonuçlar sonucu Tablo I'de gösterilmiştir.


Tablo I Bir Alt kıyafete uyumlu olan üst kıyafetin seçim sonuçları gösterilmiştir.

Örnek Ürün Kodu	Tercih Eden Kişi Sayısı				
	KÇÜA-256x256 Üst Çıktı Sonucu	KÇÜA-512x512 Üst Çıktı Sonucu	Orijinal Üst Görsele	DOK-Model1 Üst Çıktı Sonucu	DOK-Model2 Üst Çıktı Sonucu
412	1	3	3	4	0
419	4	4	2	0	1
511	3	3	1	3	1
521	2	3	1	3	2
524	3	2	3	2	1
647	2	3	3	2	1
680	6	3	2	0	0
872	1	4	2	3	1
894	4	5	1	1	0
987	4	0	2	2	3
Ortalama	3	3	2	2	1


### IV. SONUÇLAR VE DEĞERLENDİRME

#### A. Anket Sonuçları

Şekil 10 ve Şekil 11'de görüldüğü ve beklendiği üzere ÇÜA modelinin DOK modeline göre daha iyi sonuçlar alındığı gözükmemektedir. ÇÜA modelinin başarısı %50 'nin üstünde olduğu ve Orijinal eşleştirilmiş üstlere kıyasla daha çok tercih edilmiştir. Bu sayede alt kıyafetle uyumlu üretilmiş olan üst kıyafetin beğenilme yüzdesi %50'nin üstünde bir başarı sağlamaktadır.



Şekil 10 Anket Sonucuna göre iki farklı yöntemin, eşleşmiş orijinal veriye göre tercih oranları gösterilmiştir.




Şekil 11 Sonucuna göre farklı derin öğrenme modellerinin, eşleşmiş orijinal veriye göre dağılım grafiği gösterilmektedir.

#### B. MobileNet Modelinin Özellik Vektörü Çıkarım Sonuçları

Öznitelik çıkarmak için tasarladığımız modelin Şekil 12'de görüldüğü gibi %68 doğruluk oranı sağlamıştır. Bu sayede verilen bir kıyafetin kategorilerini ayırabildiği gibi,

özellik bilgilerini de çıkarabilmektedir. Modelin toplamda 2,5 milyon parametre sayısı olup, küçük ve hızlı bir model olduğu için kıyafet sentezlemek için gerekli zamanı en aza indirilmesini sağlamaktadır. Eğitimin sonuç grafikleri Şekil 12'de görüldüğü gibidir.



Şekil 12 Modelin doğruluk grafiği gösterilmiştir.

#### C. Değerlendirme

Bu bildiride, tekstil sektörü için, özgün tasarım kıyafetler üreten bir dizi derin ağ modeli geliştirilerek, ortaya çıkan tasarımların insanlar tarafından ne kadar tercih edildiği konusunda deneyler yapılmıştır. Elde edilen ilk sonuçlara göre, bu türlü bir sistemin tekstil sektörü tarafından kullanılabilirliği ve bu konuda daha fazla geliştirme yapılması için zeminin hazır olduğu fikrine varılmıştır.

#### KAYNAKLAR

- [1] Goodfellow, Ian, et al. "Generative adversarial nets." *Advances in neural information processing systems*. 2014.
- [2] Song, Yang, and Stefano Ermon. "Generative modeling by estimating gradients of the data distribution." *Advances in Neural Information Processing Systems*. 2019.
- [3] Yu, Lantao, et al. "Seqgan: Sequence generative adversarial nets with policy gradient." *Thirty-First AAAI Conference on Artificial Intelligence*. 2017.
- [4] Yu, Lantao, et al. "Seqgan: Sequence generative adversarial nets with policy gradient." *Thirty-First AAAI Conference on Artificial Intelligence*. 2017.
- [5] Iqbal, Talha, and Hazrat Ali. "Generative adversarial network for medical images (MI-GAN)." *Journal of medical systems* 42.11 (2018): 231.
- [6] Gautam, Srishti, et al. "MicroGAN: Size-invariant Learning of GAN for Super-Resolution of Microscopic Images." (2019).
- [7] Karras, Tero, et al. "Progressive growing of gans for improved quality, stability, and variation." *arXiv preprint arXiv:1710.10196* (2017).
- [8] Sandler, Mark, et al. "MobileNet V2: Inverted residuals and linear bottlenecks." *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2018.
- [9] Chollet, François. "Xception: Deep learning with depthwise separable convolutions." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.
- [10] Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional neural networks." *Advances in neural information processing systems*. 2012.
- [11] Kingma, Diederik P., and Max Welling. "Auto-encoding variational bayes." *arXiv preprint arXiv:1312.6114* (2013).
- [12] KAYNAR, Oğuz, Zafer AYDIN, and Yasin GÖRMEZ. "Sentiment Analizinde Öznitelik Düşürme Yöntemlerinin Oto Kodlayıcı Derin Öğrenme Makinaları ile Karşılaştırılması." *Bilişim Teknolojileri Dergisi* 10.3: 319-326.